


标题：棱镜合成 (Prismatic Synthesis)

副标题：基于梯度的全新数据多样化方法，显著提升大语言模型推理的泛化能力




- * 一种量化和增强“认知”多样性的新框架
- * 通过关注模型学习过程（梯度空间），而非表面文本特征，实现性能突破

标题：我们都认同数据多样性至关重要，但如何衡量“正确”的多样性？

现状与挑战

- * **普遍共识：**训练数据的多样性能够提升模型的鲁棒性、样本效率和泛化能力。
- * **根本问题：**现有度量方法大多依赖于“表面”启发式规则，例如：
 - * **词汇多样性：**不同的用词 (e.g., 2-gram entropy)
 - * **语义多样性：**文本嵌入的差异 (e.g., embedding similarity)
- * **关键缺陷：**这些表面特征与模型在复杂推理任务（如数学、逻辑推理）中的实际性能脱节。它们无法捕捉到深层的“认知多样性”。




表面词汇不同，核心推理路径却完全相同。

标题：真正的多样性不在于数据本身，而在于其对模型学习过程的影响

核心洞察：转向梯度空间

- * 我们提出，评估数据多样性的关键在于分析它如何塑造模型的“学习路径”。
- * **梯度（Gradients）**是衡量单个数据点对模型参数更新影响的直接指标。
- * 因此，训练样本在**梯度空间**中的分布，揭示了它们在“认知层面”上的差异性。
 - 梯度相似的样本，对模型的训练方式相似。
 - 梯度迥异的样本，能教会模型从不同角度解决问题。



梯度迥异的样本，代表着不同的学习影响，从而带来更高的认知多样性。

标题：G-Vendi：一个衡量认知多样性的新标尺



定义与方法

* G-Vendi 是一种新颖的度量标准，通过计算数据在梯度空间中的熵来量化其多样性。


工作原理



1. **收集梯度表示**：使用一个现成的小型代理模型（off-the-shelf proxy model）计算每个数据点的损失梯度。




2. **降维**：通过随机投影将高维梯度向量降至一个可管理的维度（e.g., 1024-dim），同时保留其内部结构。




3. **计算熵**：计算梯度协方差矩阵的指数熵（Vendi Score）。

直观解释



低 G-Vendi 分数：梯度集中，认知多样性低。



高 G-Vendi 分数：梯度分布广泛，认知多样性高。



关键优势

* 计算高效，无需针对特定任务进行模型微调或复杂的权重分解。

标题：G-Vendi 分数与模型泛化能力呈惊人的强相关性

大规模实证分析（超过300次训练运行）：

- * 我们在数学推理和自然语言推理（NLI）任务上进行了严格的对照实验。
- * 结果显示，G-Vendi 分数是模型在未见过分布（OOD）数据集上性能的强大预测指标。




标题：对于 OOD 泛化，多样性比规模更重要


实验发现：

- * **OOD 性能**：一个拥有更高 G-Vendi 分数的小型数据集（例如 10k 样本），其训练出的模型性能往往优于一个多样性较低但规模大10倍的数据集（100k 样本）。
- * **ID 性能（In-Distribution）**：数据规模是提升分布内性能的主导因素。多样性与规模互为补充。

OOD Generalization



ID Performance



关键结论： 优先提升数据的认知多样性是实现卓越 OOD 泛化能力的关键策略。

标题：G-Vendi 捕捉的是“推理模式”，而非“表面语义”

对照实验设计：

- * **DiverseReason**：包含丰富的推理模式，但主题和措辞范围较窄。
- * **DiversePersona**：包含广泛的主题和多样的措辞（通过 persona prompt），但推理模式较少。

实验结果（来自 Table 2）

Dataset	OOD Performance	G-Vendi Score	Embedding Vendi
DiverseReason	63.48	103.63	30.79
DiversePersona	42.14	87.86	31.16

洞察：

- * **G-Vendi** 正确地识别出 DiverseReason 具有更高的“有效”多样性，其训练出的模型性能也更强。
- * **Embedding Vendi** 等基于语义的度量方法则被表面多样性误导，错误地偏爱 DiversePersona。

标题：棱镜合成（Prismatic Synthesis）：一个主动生成多样性数据的框架

核心理念

- * 利用 G-Vendi 作为引导，主动在梯度空间的**低密度区域**生成新的合成数据，从而系统性地提升数据集的认知多样性。

三步迭代循环

1. **聚类（Cluster）**：在梯度空间中对现有数据点进行聚类。
2. **生成（Generate）**：使用已有数据作为少样本示例（few-shot examples），提示大语言模型生成新样本。
3. **多样化（Diversify）**：仅保留那些落入稀疏聚类（sparse clusters）的新样本，并将其加入数据池。



标题：应用棱镜合成：构建两个SOTA级合成数据集

Nemotron-PrismMath（数学推理）

- **生成器**：使用 Qwen2.5-72B-Instruct 生成问题，R1-32B（R1-Distill-Qwen-32B）生成解题步骤。
- **质量控制**：通过多路径答案一致性投票进行自动验证。
- **最终规模**：100万个高质量的“问题-解题过程”对。


PrismNLI（自然语言推理）

- **生成器**：使用 Qwen2.5-72B-Instruct 生成前提、假设和标签。
- **质量控制**：自动验证。
- **最终规模**：51.5万个“输入-标签”对。

关键特点： 整个流程完全自动化，无需任何人工标注或答案验证。

标题：PrismMath-7B 刷新数学推理 SOTA：以小胜大

数学推理基准测试平均性能



核心对比

“David vs. Goliath” 故事，以及“数学基准测试的下率：

- **PrismMath-7B**：使用 7B 基础模型，训练数据由 **32B** 模型（R1-32B）生成。
- **SOTA 竞品**：使用 7B 基础模型，训练数据由 **671B** 模型（R1-671B）生成。

数据来自 **32B 生成器**，性能超越数据来自 **20倍以上规模（671B）的生成器！**

结果：PrismMath-7B 在 7 个极具挑战性的数学基准测试中的 6 个上取得了最先进的结果。

标题：PrismNLI 在自然语言推理任务上取得压倒性优势

对比基准：将 PrismNLI 与多个广泛使用的大规模 NLI 数据集的混合体（如 WANLI + MNLI + SNLI）进行比较。

NLI 任务 OOD 平均准确率




结果：

- **性能提升：**在 8 个 OOD 基准上，PrismNLI 的平均准确率比之前最佳的数据集混合体高出 8%。
- **数据效率：**PrismNLI 的规模仅为基准数据集的一半，且完全不依赖人工标注。

标题：简单的规模扩张已触及瓶颈，而棱镜合成持续带来提升


实验对比：在数学数据合成中，比较不同策略的扩展效果。



结论：没有原则性多样化策略的盲目数据扩展，回报会迅速递减。棱镜合成为实现持续性能增长提供了有效路径。

标题：核心结论：基于梯度的多样化是提升模型泛化能力的关键驱动力

回顾：



1. **问题：**表面化的数据多样性度量无法指导模型在复杂推理任务上的泛化。



2. **洞察：**真正的多样性存在于梯度空间，它反映了数据对模型学习过程的影响。



3. **方法：**我们开发了 **G-Vendi**（高精度预测泛化能力的标尺）和 **棱镜合成**（在梯度空间中主动生成多样性数据的引擎）。



4. **证明：**我们的方法生成的 **PrismMath** 和 **PrismNLI** 数据集，在极具挑战性的基准上取得了 SOTA 性能，证明了该方法的有效性和效率。

最终论点：有原则的、基于梯度的多样化，比盲目扩大数据规模或依赖启发式方法更有效、更高效。

标题：技术细节与深入分析

1. G-Vendi 公式

$$\text{G-Vendi}(D) = \exp \left(- \sum_i \lambda_{k_i} \log \lambda_{k_i} \right)$$

- 其中 λ_{k_i} 是归一化协方差矩阵 K 的第 i 个特征值。这继承了 Vendi Score 的优良特性，如排列不变性，且计算复杂度为 $O(d^2|D|)$ ，远优于成对相似度计算的 $O(d|D|^2)$ 。

2. G-Vendi 在不同代理模型下的稳定性（来自 Table 3）

Proxy Model	ρ w/ Qwen2.5-0.5B-It	ρ w/ OOD Perf.
Llama-3.2-1B-It	0.899	0.909
Qwen2.5-0.5B	0.811	0.772

- G-Vendi 对代理模型的选择具有鲁棒性...其与 OOD 性能的秩相关系数（rank correlation）始终保持高位。

3. 使用的 OOD 基准测试

- 数学：** SAT-Math, MMLU (Elementary, High School, College), GSM-IC, Aqua-RAT, Minerva-Math
- NLI：** HANS, WNLI, ANLI, QNLI, NLI Diagnostics, BigBench NLI, ConTRoL

标题：梯度空间聚类揭示了什么？—— 共同的推理策略

定性分析：梯度空间中同一簇的样本，往往共享微妙的、共同的推理策略，而非表面的主题或语义重叠。

NLI 示例：概念间的成员关系 (Membership between concepts)

- **样本 1：**Rosa Parks 坐在公交车前四排，而前四排是为白人保留的 → Rosa Parks 坐在了白人区。
- **样本 2：**赢得四大满贯（澳网、法网、温网、美网）即为“大满贯” → 赢得法网和其他三项，即赢得大满贯。
- **样本 3：**“三冠王”包括肯塔基德比等三项赛事 → 赢得“三冠王”的 American Pharoah 赢得了肯塔基德比。

数学示例：分步状态追踪 (State tracking step-by-step)

所有问题都需要根据初始条件，通过一系列依赖关系逐步计算出中间值，最终得出总和。

- **样本 1：**Simon 的木筏 → Gerry 的木筏 → Micky 的木筏 → 总和
- **样本 2：**雪花邮票 → 卡车邮票 → 玫瑰邮票 → 总和
- **样本 3：**跑步罚时 → 扔食物罚时 → 咒骂罚时 → 总罚时